葡萄成熟度与采摘点同步检测方法

刘 瑞[1]，常帅兵[1]，金主贵[1]，葛永琪[1,2]，孙志峰[3]

（1. 宁夏大学信息工程学院，银川 750021；2. 宁夏“东数西算”人工智能与信息安全重点实验室，银川 750021；3. 银川方达电子系统工程有限公司，银川 750021）

摘 要：为实现成熟葡萄与采摘点的同步检测，保障果实品质并提升采收效率，该研究针对现有非同步分离检测方法中存在的流程复杂、模型冗余度高、效率低和计算资源消耗大等问题，提出一种葡萄成熟度和采摘点同步检测方法（a synchronous detection method for grape ripeness and picking point localizations, GrapickNet）。该方法由能同步检测葡萄成熟度与果梗关键点的改进模型（Grapick-YOLO12n）和基于多重约束规则的果串-采摘点匹配算法（a bunch-pick point matching algorithm based on multiple constraint rules, RBPM）组成。Grapick-YOLO12n 以 YOLO12n-pose 为基准模型，设计了边缘信息传递模块（edge information transfer module, EIFT）模块和 C3K2_RFAConv 模块，增强了模型对密集遮挡的葡萄果串成熟度和细小果梗的多尺度特征提取能力。RBPM 算法通过构建多重约束规则，实现了葡萄果串与采摘点的高精度空间关联。在涵盖多场景、多光照条件和多品种的自建温室葡萄 RGB 图像数据集（4 383 张）的试验结果表明，GrapickNet 在成熟度识别任务中的 mAP@0.5 达到 88.9%，采摘点检测的精确率为 82.7%。较基准模型（成熟度 mAP@0.5 87.0%，采摘点精度 77.8%）分别提升了 1.9 和 4.9 个百分点，且模型参数量仅为 3.33 M。在定位精度方面，X、Y 方向的平均误差分别为 2.51 像素和 5.37 像素，欧式距离平均误差为 6.39 像素。该研究为温室半结构化环境下葡萄自动化采收提供了一种高效、准确的方法参考。

关键词：葡萄；成熟度；YOLO12n-pose；同步检测；采摘点

doi：10.11975/j.issn.1002-6819.202512115

中图分类号：S24 **文献标志码**：A **文章编号**：1002-6819(2026)-15-0262-11

刘瑞，常帅兵，金主贵，等. 葡萄成熟度与采摘点同步检测方法[J]. **农业工程学报**，2026，42(15)：262-272. doi: 10.11975/j.issn.1002-6819.202512115 http://www.tcsae.org

Liu Rui, Chang Shuaibing, Jin Zhugui, et al. Detecting grape ripeness to synchronously locate picking point during harvesting[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2026, 42(15): 262-272. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202512115 http://www.tcsae.org

0 引 言

随着设施农业的发展，温室葡萄的种植规模不断扩大，但生产成本也呈逐年攀升趋势[1-2]。葡萄成熟过程受光照、养分、品种和个体差异等因素影响，其成熟度常呈现非同步性[3-4]。实现成熟果实的精准判别与同步采收，是保障果实价值与提升种植经济效益的关键环节。然而，目前温室葡萄采收仍主要依赖人工，不仅劳动强度大、效率低、成本逐年上涨，更因高度依赖采摘者经验而易导致成熟度误判，严重影响果实品质和产业效益的稳定性[5]。因此，发展采摘机器人已成为推动产业升级的必然趋势，而机器人自主高效作业的关键技术之一是实现成熟葡萄与采摘点的快速、准确同步检测与定位。

随着计算机视觉技术的蓬勃发展，葡萄性状检测研究取得了显著进展。在成熟度检测方面，主要包括光谱分析和 RGB 图像识别两种方法。光谱分析通过获取果实的高光谱特征实现成熟度评估[6-8]。该类方法实现了葡萄成熟度的无损检测，但高光谱系统成本高昂且易受田间遮挡的影响。相较于光谱分析，RGB 图像的识别方法具有成本低、易部署的优势。马鹏伟等[9] 在 YOLOv7 模型的颈部网络融入注意力机制，实现了大田环境下赤霞珠葡萄成熟度识别，在测试集上的精确度达 95.2%，但内存占用较高，达 53.6 MB。这表明 RGB 识别方法能实现葡萄成熟度的高精度识别，但模型的轻量化性能仍有待提升。此外，现有研究对温室场景中葡萄成熟度与采摘点多任务同步检测关注不足。

在采摘点定位研究方面，早期研究主要通过阈值分割、传统特征提取算法和形态学操作将果实与背景分离，再通过统计计算确定采摘点[10-11]。该类方法需手动设计大量视觉特征，模型泛化能力不足且在复杂环境中易受噪声影响。随着深度学习技术的发展，基于 Mask R-CNN、YOLO 和 Transformer 等网络的果串、果梗及采摘点识别方法表现出了较高的特征学习能力与环境适应性[12-14]。研究者通过引入姿态估计模型[15-16]、位置约束机制[17] 和强化学习框架[18] 等方法，探索了深度学习在葡萄果实、果梗及采摘点检测与定位中的应用。Jin 等[19] 基于葡萄果梗与果穗间的几何分布构建果梗 ROI，结果表明考虑果实与果梗位置约束可实现低损的采摘点定位，在晴天条件下的成功率为 92%。然而，由于葡萄果串、

收稿日期：2025-12-15 修订日期：2026-05-21

基金项目：国家自然科学基金地区项目（62162052，62262052）；宁夏自然科学基金项目（2025AAC020024，2025AAC030156）

作者简介：刘瑞，博士，副教授，研究方向为数字农业、农业信息物理系统。Email：ruiliu@nxu.edu.cn

中国知网 https://www.cnki.net

果梗及采摘点之间存在显著的尺度差异，现有方法在定位精度与效率方面仍面临挑战。也有研究者提出基于双节点网络的酿酒葡萄采摘点定位方法，实现了葡萄果实远距离检测和果梗采摘点精准定位[20]。但这种两阶段非同步检测架构存在流程繁琐、效率较低的局限性。

温室环境作为半封闭系统，其独特的光照条件与空间结构为基于 RGB 图像的葡萄成熟度和采摘点同步检测带了多重技术挑战。从任务特性来看，成熟度和采摘点属不同尺度的识别任务，前者主要依赖于颜色、纹理等表观特征，后者则需精确感知果梗图像的几何结构和空间位置，这种本质差异对于多任务同步检测模型提出了更高的要求。从环境特性分析，温室建筑结构产生的阴影与薄膜表面的光线折射、反射现象，极易导致果实颜色失真，进而影响基于颜色特征的成熟度判别精度。此外，在温室半结构化种植模式下，葡萄果实分布密集，果梗细长且相互交错，使得遮挡、重叠和背景干扰问题尤为突出，进一步增加了精准检测的难度。

基于以上背景，本研究提出葡萄成熟度与采摘点同步检测方法（a synchronous detection method for grape ripeness and picking point localizations, GrapickNet），旨在提升复杂温室环境下多品种葡萄成熟度和采摘点同步检测与定位的综合性能，为采摘机器人在温室的可靠作业提供技术解决方案。

1　材料与方法

1.1　研究区概况

本研究数据采集自宁夏银川市西夏区一处符合 GAP（good agricultural practice）标准的温室葡萄种植基地（38°48'21"N，106°06'01"E）。该基地位于贺兰山东麓冲积扇平原，平均海拔约 1 120 m，属典型大陆性干旱气候，具有日照充足、昼夜温差大等特点。土壤类型为轻壤质淡灰钙土，富含钙、镁、钾等矿质元素。该地区气候与土壤条件有助于葡萄糖分和风味物质积累，利于高品质葡萄生长。

1.2　数据集构建

1.2.1　图像采集

数据采集时间为 2025 年 6—8 月，共采集了 10 次。采集设备包括 Intel RealSense D455F 深度相机（640×480 像素）、一加 Ace3 Pro 智能手机（3 072×4 096 像素）及索尼 ZV-E10 相机（1920×1 080 像素），图像获取距离动态设定在 0.3～1.5 m。为提升数据集质量并增强模型的鲁棒性，本研究选取了宁夏地区广泛种植的 5 个葡萄品种——玫瑰香、蓝宝石、蜜光、查娜和红提，分简单环境（簇个数≤2）和复杂环境（簇个数>2）两个场景，拍摄不同品种葡萄未成熟期和成熟期的 RGB 图像。采集场景覆盖了 4 种典型自然光照条件：晴天顺光、晴天逆光、阴天和雨天。受限于采集区降雨稀少，未成熟雨天数据仅采集了 1 次。光照强度使用希玛 AS803 高精度照度计测定，测量误差控制在±0.02% 以内。在上述 4 类光照条件下，测得的最大光照度分别为 39 060、12 860、7 316 和 3 877 lx。最终共获得涵盖温室不同光照条件和不同品种的葡萄图像 4 383 幅，具体数据组成及规模见表 1。同步开展田间实地葡萄成熟度观察。为适配于自动化采摘系统，本研究采用色度测量方法[9]，在当地葡萄种植经验丰富的果农帮助下，将葡萄果实依据色泽进行成熟、未成熟划分，同步确定最佳采摘点位置。其中，成熟期玫瑰香、蓝宝石和蜜光果皮为黑紫色，未成熟期果皮为黄褐色或浅绿色；成熟期红提和查娜果皮为紫红色，未成熟期果皮为浅红色或浅绿色。图 1 为部分复杂温室环境下不同品种葡萄的样本图像。

表 1　数据集组成与规模

Table 1　Composition of grape image dataset

光照条件 Light conditions	简单环境 Simple environment		复杂环境 Complex environment		总计 Total
	成熟 Ripe	未成熟 Unripe	成熟 Ripe	未成熟 Unripe	
晴天顺光 Front lighting on sunny days	821	139	402	352	1 714
晴天逆光 Backlighting on sunny days	296	178	307	432	1 213
阴天 Overcast sky lighting	201	112	212	521	1 046
雨天 Rainy conditions	155	6	229	20	410



a. 晴天逆光+未成熟 a. Backlighting+unripe　b. 晴天顺光+未成熟 b. Front lighting+unripe　c. 阴天+成熟 c. Cloudy day+ripe　d. 雨天+成熟 d. Rainy day+ ripe

e. 果串遮挡+未成熟 e. Grapes occlusive+unripe　f. 密集+成熟 f. Dense+ripe　g. 果梗斜茎+未成熟 g. Obliquely stems+unripe　h. 果梗遮挡+未成熟 h. Stems Occlusive+unripe

图 1　温室环境下葡萄样本图像

Fig.1　Grape sample images from greenhouse environments

1.2.2　图像预处理

为优化数据标注流程并提升数据集质量，本研究分三步对数据集进行了预处理：1）图像筛选：在温室复杂环境下拍摄的部分图像可能因光照条件不佳或对焦不准而出现模糊、阴影或过曝等问题。为不影响数据集质量，对原始图像进行了筛选；2）数据标注：采用 LabelMe 工具对筛选后的 RGB 图像进行人工标注。通过矩形标注框标注果串和果梗，使用关键点标注最佳采摘点。成熟果串、未成熟果串、果梗和采摘点样本分别标注为 Frgc、Urgc、stem 和 point，为每个标注区域附加相应的属性信

中国知网　https://www.cnki.net

息，并通过多人交叉复核方法对标注结果进行核验。最终，构建了温室环境下包含 5 个不同品种的 4 383 张葡萄图像数据集，数据集详细规模及样本分布见表 1；3）数据集划分与归一化：为减少光照、拍摄角度及背景差异带来的分布偏差，采用随机抽样方法将数据集按 6:3:1 的比例划分为训练集、验证集和测试集。模型训练之前先采用信封填充算法将标注图像压缩为 640×640 像素，再对图像像素值进行归一化，将其缩放至 0～1 区间，以提升训练过程的数值计算效率。

1.3 葡萄成熟度与采摘点同步检测建模

1.3.1 改进的 YOLO12n-pose 模型

YOLO12n 作为 YOLO 系列的最新版本，其核心改进在于将注意力机制与实时检测技术结合，实现了检测速度与精度的双重突破，更适用于复杂场景下葡萄果实和果梗的轻量化检测任务[21]。然而，YOLO12n-pose 在温室复杂环境下仍存在一些性能瓶颈。如：由光照引起的葡萄果实颜色失真、果串分布密集、多尺度目标间的遮挡、重叠及复杂背景干扰等因素，导致模型在边界特征建模方面表现不足，出现漏检或误检问题。因此，仍需对 YOLO12n-pose 进一步改进，在增强其对模糊边缘特征提取能力的同时扩大模型感受野，以提升多尺度目标的检测性能。通过强化模型在复杂温室环境下的鲁棒性与泛化能力，使其能够更好地适应多样化种植园的实际应用需求。因此，本研究以 YOLO12n-Pose 为基准架构，提出了一种改进的 Grapick-YOLO12n 模型，旨在实现葡萄果串成熟度、果梗及采摘点多目标同步识别，改进的模型结构如图 2 所示。

Grapick-YOLO12n 模型的核心架构改进主要包括两个方面：1）在网络浅层设计了边缘信息传递模块（edge information transfer module, EIFT），通过集成多尺度边缘特征生成与跨通道融合机制 ConvEdgeFusion，增强了模型对目标边界和局部细节的感知能力，有效提升模型在复杂背景、颜色失真和部分遮挡场景下的检测精度；2）将 RFAConv 模块引入到骨干网络和颈部网络，对原网络中的 C3K2 和 Conv2 d 模块进行了优化。一方面，将 RFAConv 模块引入 C3K2 模块，通过替换其中的 C3K 模块构建了 C3K2_RFAConv 模块；另一方面，用 RFAConv 模块替换原有的标准 Conv2 d 卷积层，构建了 FCBS 模块。该改进借助 RFAConv 模块的双通道并行优势，使其能够同时捕获多尺度上下文信息，有效克服了传统卷积在特征提取中感受野有限、难以充分捕捉多尺度目标全局信息的局限。本研究通过上述两个方面的改进优化，使模型在面对检测多目标之间交织生长、颜色失真、遮挡和小尺度时，能更全面、更精准地感知其结构特征，从而提升整体检测精度、训练稳定性与模型鲁棒性。

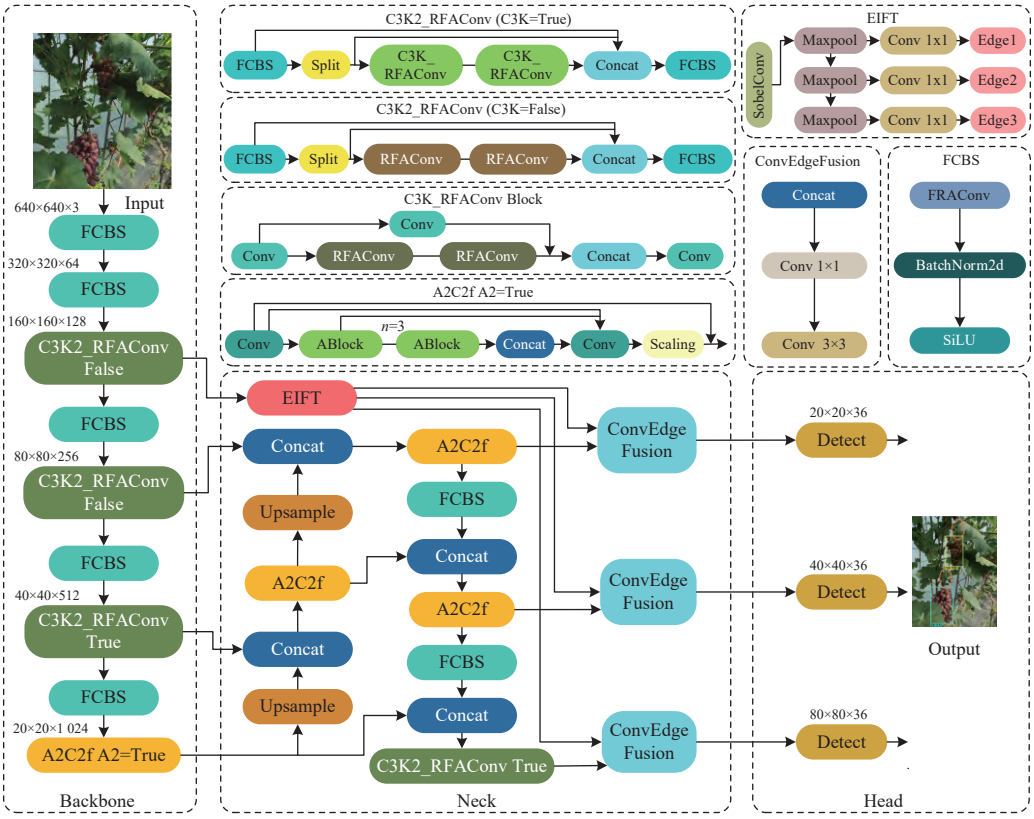


图 2 改进的 Grapick-YOLO12n 结构

Fig.2 Improved Grapick-YOLO12n model structure

1）EIFT 模块

温室环境下的葡萄成熟度、果梗及采摘点检测任务面临多重挑战：温室复杂光照、葡萄品种多样、果梗形态细长，且未成熟葡萄颜色常与背景高度相似、加之严重的遮挡与重叠现象，导致检测目标常出现边界模糊与轮廓缺失。传统检测模型由于对边缘特征的建模能力不

中国知网 https://www.cnki.net

足，在此类场景下常存在细粒度识别性能下降与鲁棒性受限的问题。为此，本研究设计了边缘信息传递模块，其结构如图 3。该模块能够从浅层卷积特征中提取边缘信息，经过多尺度增强与跨层传递机制处理后，将强化后的边缘细节注入颈部网络的不同层级特征中。该机制通过浅层边缘信息提取有效抑制了背景干扰，弥补了传统模型在边界表征方面的不足，增强了对模糊边缘的感知能力与建模能力，有助于提升模型的细粒度检测精度及其在复杂场景下的鲁棒性。

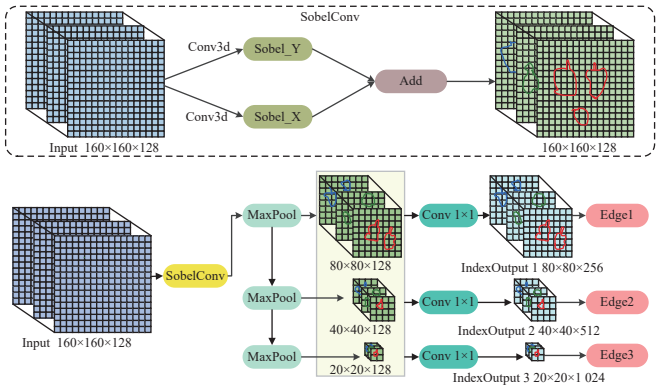


图 3　EIFT 模块结构

Fig.3　EIFT module structure

由图 3 所示，EIFT 模块分三步实现温室环境下葡萄成熟度、果梗及采摘点边缘细节提取：首先，利用 SobelConv 算子，分别在输入特征图的水平与垂直方向计算梯度分布，并将二者叠加得到边缘响应图，从而显式地捕获目标的轮廓信息。然后，在下采样阶段，为压缩特征图尺寸的同时保留并增强边缘信息，选用 MaxPool 操作。与更适合平滑或均匀化特征 AvgPool 相比，MaxPool 能够保留局部的最强响应，从而更好地凸显边缘特征。最后，ConvEdgeFusion 模块负责将上述步骤得到的多尺度边缘特征与主干网络中的卷积特征在通道维度上进行拼接。该模块先通过一个 1×1 卷积实现跨通道信息的压缩与融合，再利用一个 3×3 卷积进一步提取局部上下文信息，最后使用另一个 1×1 卷积调整输出维度，最终生成增强后的多尺度特征图，其计算过程见式（1）～（4）。

$$E_i = \mathrm{EdgeGen}_i(X)\, i = 1, 2, \cdots, N \tag{1}$$

$$\hat{E}_i = \mathrm{MaxPool}(E_i) \tag{2}$$

$$F_i = \mathrm{Conv}_{fusion}\left(X \oplus \hat{E}_i\right) \tag{3}$$

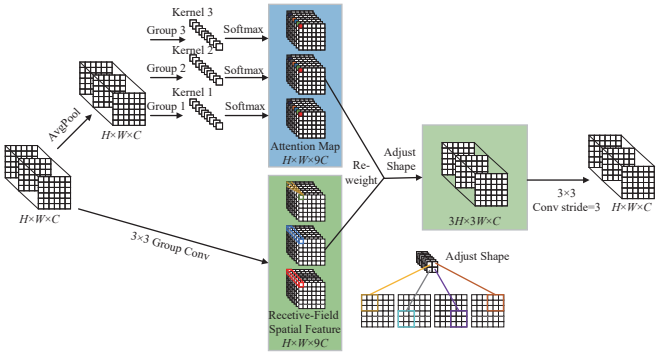
$$\tilde{X} = \mathrm{Conv}_{1\times1}(F_i) \tag{4}$$

式中 X 表示输入浅层特征，E_i 为第 i 个尺度的边缘特征，$\hat{E}_i$ 为下采样后的边缘特征，$\oplus$ 表示特征拼接操作，$\mathrm{EdgeGen}_i$ 表示第 i 个尺度的边缘特征生成函数，MaxPool 表示最大池化操作，F_i 为拼接融合后的中间特征图，Conv_{fusion} 表示跨通道融合卷积，$\tilde{X}$ 为输出增强特征图。

2）RFAConv 模块

RFAConv 是一种注意力机制，旨在通过引入感受野空间特征来优化标注卷积操作，其网络结构如图 4 所示。该模块采用了一种双通道并行设计以克服传统空间注意力在参数共享方面的局限。在注意力通道中，通过全局平均池化、组卷积及 Softmax 函数生成空间注意力权重，实现对特征图空间重要性的差异化分配。在感受野通道中，通过组卷积、归一化及 ReLU 函数构建非线性的感受野特征表示。两个通道的输出经逐元素乘融合后，再经由 stride=3 标准卷积进行尺度调整，最终生成输出特征图。

温室葡萄成熟度、果梗及采摘点的检测任务中，不同尺度目标共存，小尺度目标易受周围像素干扰而淹没，这使得传统模型难以有效适应多尺度目标的特征分布，对大尺度和小尺度目标的特征捕捉能力不足。为此，本研究引入 RFAConv 模块，具体改进方法如下：1）使用 RFAConv 模块直接替换原有网络中的标准 Conv2 d 卷积层；2）构建 C3K2_RFAConv 以替代原有 C3K2 模块。在 C3K2 模块中，本研究将原 Bottleneck 层替换为 RFAConv 模块。其中，当 C3K2_RFAConv C3K=False 时，使用 RFAConv 替换 Bottleneck 层；当 C3K2_RFAConv C3K=True 时，使用 C3K_RFAConv 替换原 C3K。这一改进利用了 RFAConv 的双通道并行机制，能够同步提取多尺度目标中的全局上下文信息与局部细节特征，从而有效缓解在温室复杂背景下密集分布的多尺度目标检测中存在的特征混淆与信息丢失问题。



注：H 为高度，W 为宽度，C 为通道数，$9C$ 为通道数扩展为原来的 9 倍，Conv 为卷积。

Note: H denotes height, W denotes width, C denotes the number of channels, $9C$ indicates that the number of channels is expanded to 9 times the original, and Conv represents convolution.

图 4　RFAConv 模块及改进的 C3K2_RFAConv 模块结构

Fig.4　Structure of RFAConv module and improved C3K2_RFAConv module

1.3.2　基于多重约束规则的果串-采摘点匹配算法

为实现葡萄果串与采摘点之间的空间准确匹配，本研究设计了一种基于多重约束规则的果串-采摘点匹配算法（a bunch-pick point matching algorithm based on multiple constraint rules, RBPM）。由于检测模型输出的果串成熟度与采摘点均为离散实例，需通过匹配策略判定各采摘点是否满足采摘条件。该方法通过多重约束条件，有效提升成熟果串与采摘点的成功匹配率，避免实际作业中因误判导致的采摘错误。根据针孔相机成像模型、采摘机器人实际工作范围（0.5～0.8 m）和葡萄果梗农艺特征，

中国知网　https://www.cnki.net

本文将采摘点与果串上边框中心点的欧式距离设定为 20 像素。算法流程分为 4 步：

1）初始化列表：分别构建成熟葡萄果串候选列表与可见采摘点列表。

2）距离计算与排序：对每一个成熟葡萄果串依次遍历采摘点列表，计算采摘点纵坐标与果串检测框上边框中心点之间的欧式距离，并将所有距离结果存入列表并进行升序排序。

3）多重约束匹配：在距离排序基础上，引入多重约束条件以提升匹配准确性。

约束①：采摘点的纵坐标高于葡萄果串检测框左上角顶点的纵坐标；

约束②：采摘点位于对应葡萄果串的检测框内；

约束③：采摘点与果串上边框中心点的欧式距离须小于 20 像素。

其中，约束③为匹配的必要条件，约束①与约束②的组合亦为必要条件，约束①的优先级高于约束②，为并集关系，满足其一即可匹配。

4）结果分配：根据排序结果与约束条件为每个葡萄果串匹配唯一的采摘点。若遍历后未找到满足全部条件的采摘点，则判定该果串不具备采摘条件。

1.4 网络模型训练

1.4.1 运行环境配置

本研究所有试验均在 Ubuntu 20.04 LTS 操作系统下完成。硬件环境采用 Intel(R) Xeon(R) Silver 4310 CPU @ 2.10 GHz 处理器，配备 2 块 NVIDIA GeForce RTX 4090 GPU，单卡显存为 24 GB，软件环境基于 Python 3.12 和 CUDA 13.0 加速库。图像输入大小为 640×640 像素。考虑到试验的可比性，所有模型都是在本研究建立的数据集上训练，训练参数进行了统一设置，训练轮次为 300。为了优化模型参数并最小化损失函数，使用动量参数为 0.937 的 SGD 优化器，设置随机种子为 0。

1.4.2 模型评价指标

使用精确率（precision, P）、召回率（recall, R）、平均精度均值（mean average precision, mAP）作为评估指标，以衡量模型对葡萄果串成熟度和果梗的识别性能。为评估采摘点定位精度，引入水平方向平均像素距离（D_x）、垂直方向平均像素距离（D_y）和平均像素欧氏距离（D_ε）对模型进行综合评估[22]。此外，为评估模型复杂度，引入模型参数量、计算量（FLOPs）和推理速度（FPS）。

2 结果与分析

2.1 不同光照条件葡萄果串成熟度与果梗识别结果分析

为评估改进的 Grapick-YOLO12n 模型在温室复杂光照环境下的检测性能，本研究开展了不同光照环境下多品种葡萄果串成熟度与果梗多目标检测测试。由表 2 可知，Grapick-YOLO12n 模型在复杂温室光照条件下，对不同品种葡萄的果串成熟度及果梗检测均表现出稳健的检测性能。模型对果串成熟度的检测精度在 76.9%~85.1% 内，对果梗的检测精度保持在 86.7%~89.7% 内，这表明该模型能够较好地适应温室多变的光照环境，实现了对多品种葡萄成熟度和果梗的准确检测。

表 2 不同光照葡萄果串成熟度与果梗检测结果

Table 2 Ripeness of grape clusters and stem detection results under different lighting %

光照条件 Lighting conditions	果串成熟度 Bunch ripeness				果梗 Stem			
	P	R	mAP@0.5	mAP@0.5-0.95	P	R	mAP@0.5	mAP@0.5-0.95
晴天顺光 Front lighting on sunny days	85.1	81.0	89.1	64.5	88.3	69.8	79.7	36.2
晴天逆光 Backlighting on sunny days	84.0	88.6	91.7	68.6	87.6	78.6	85.1	39.9
阴天 cloudy day lighting	78.8	87.6	88.1	63.8	89.7	80.4	89.9	41.2
雨天 Rainy conditions	76.9	72.2	82.8	52.9	86.7	69.2	77.5	36.2

深入分析表 2 发现，模型在晴天顺光和逆光条件下对果串成熟度表现出了较高的识别能力，mAP@0.5 分别达到 89.1% 和 91.7%。模型在不同光照条件下都对果梗保持了较好的识别精度，尤其在阴天环境中性能最优，精确度、召回率和 mAP@0.5 分别达到 89.7%、80.4% 和 89.9%，漏检率显著降低。在雨天低光照和雨滴噪声干扰下，模型整体检测精度有所下降，但其对果梗检测的 mAP@0.5 仍保持在 77.5%，说明模型在雨天仍具备较稳定的识别能力。此外，果梗检测的 mAP@0.5-0.95 指标相对较低，这是由于该指标对小像素目标计算较为敏感，轻微的预测框偏移即会导致 IoU 阈值得分快速下降，这与 Zhang 等[23] 的研究结论一致。此外，综合采摘机器人末端执行器容错半径（15 mm）和采摘点物理定位误差范围（8.25～13.20 mm），该指标的少量像素偏差对采摘点执行判断的影响较小。因此，改进的 Grapick-YOLO12n 模型能够较好的适应温室环境中逆光过曝、前景阴影、光照不足及雨滴噪声等多重干扰，在不同光照条件下都能实现多尺度目标的稳定识别，具有良好的鲁棒性与环境适应性。

2.2 不同算法模型对比

为进一步验证 Grapick-YOLO12n 模型的有效性，选择当前主流轻量级模型在相同训练环境下进行对比试验。由表 3 可得，改进的 Grapick-YOLO12n 模型在果串成熟度和果梗检测任务中表现出较好的综合性能，其对果串成熟度和果梗检测的 mAP@0.5分别为 88.9% 和 84.4%。整体性能优于对比模型，参数量仅为 3.33 M，能满足轻量化性能要求（<5 M）[24]。进一步分析表 3 发现，SSD 模型在果串成熟度检测中虽具有最高的精确率，但其召回率、mAP@0.5 和 mAP@0.5-0.95 低于本文模型，且 FLOPs 与参数量远高于本文模型。在 YOLO 系列中，YOLOv8n-pose 和 YOLO12n-pose 分别在果串成熟度和果梗检测中表现最佳，但在精确率、召回率与 mAP 等关键指标上仍不及本文模型。相较于原 YOLO12n-pose，

中国知网 https://www.cnki.net

本文模型对成熟度检测的精确率和召回率分别提升至85.3% 和 82.9%，对果梗的检测提升至 89.8% 和 76.5%。本文模型在提高检测精度的同时降低了漏检率，增强了模型复杂温室环境中果串成熟度与果梗位置的识别能力。尽管参数量较基线模型增加了 0.76 M，但仍远低于 Faster R-CNN、SSD 和 RT-DETR等主流实时检测模型。本文模型推理速度为 94.6 帧/s，虽低于 YOLO 系列对比模型，但显著高于 Faster R-CNN、SSD 和 RT-DETR。图 5 为训练过程中损失和指标变化比较，图 6 为不同模型在不同遮挡场景下的检测性能对比。

表 3　不同模型检测结果对比

Table 3　Comparison of detection results of different models

检测目标 Detection target	模型 Model	*P*/%	*R*/%	mAP@0.5/%	mAP@0.5-0.95/%	计算量 FLOPs/G	参数量 Parameters/M	推理速度 FPS/(帧·s^{-1})
果串成熟度 Bunch ripeness	YOLOv5n-pose	82.8	79.6	86.8	61.5	7.3	2.65	156.1
	YOLOv8n-pose	86.2	81.3	87.1	63.0	8.4	3.00	165.4
	YOLOv10n-pose	84.1	81.3	87.7	62.7	8.2	2.65	144.5
	YOLO11n-pose	85.7	80.9	87.9	63.1	6.6	2.58	128.2
	YOLO12n-pose	84.6	80.9	87.0	62.8	6.5	2.57	102.8
	Faster R-CNN	57.7	85.4	82.3	54.0	134.4	41.80	10.6
	SSD	87.9	75.6	83.4	55.5	31.0	18.90	22.8
	RT-DETR	84.6	74.3	79.6	55.1	57.0	18.90	38.5
	Grapick-YOLO12n	85.3	82.9	88.9	65.4	8.4	3.33	94.6
果梗 Stem	YOLOv5n-pose	86.0	73.7	80.1	35.8	7.3	2.65	156.1
	YOLOv8n-pose	87.9	74.6	81.9	37.1	8.4	3.00	165.4
	YOLOv10n-pose	86.2	74.9	81.3	37.6	8.2	2.65	144.5
	YOLO11n-pose	86.8	72.7	82.0	37.9	6.6	2.58	128.2
	YOLO12n-pose	89.4	73.3	81.8	36.8	6.5	2.57	102.8
	Faster R-CNN	31.4	36.2	25.7	10.1	134.4	41.80	10.6
	SSD	88.4	11.6	43.0	17.1	31.0	18.90	22.8
	RT-DETR	82.8	70.2	77.0	33.7	57.0	18.90	38.5
	Grapick-YOLO12n	89.8	76.5	84.4	39.6	8.4	3.33	94.6

由图 5 可知，改进的 Grapick-YOLO12n 模型表现出较快的收敛速度。最终定位损失收敛至 0.834，较基线模型降低 9.1%。分类损失和关键点损失分别收敛至 0.532 和 0.016，与基线模型基本持平。这表明 RFAConv 和 EIFT 的引入有效优化了模型对边界框定位的精度，同时保持了果串成熟度分类的判别能力。

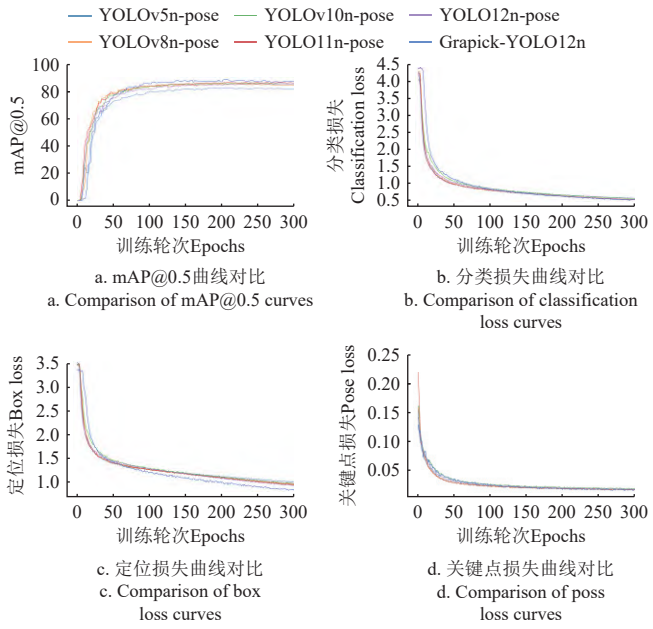


图 5　训练过程中损失和指标变化对比

Fig.5　Comparison of loss and metric changes during training

观察图 6 发现，改进的 Grapick-YOLO12n 模型在所有测试场景中均表现出较高的检测效果，能够准确区分各品种葡萄的成熟度与果梗。而 YOLO 系列和实时检测模型在远景和密集场景下均出现了对果串和果梗检测的较高误检率。其中，RT-DETR 模型在远景密集成熟果串和未成熟果串与背景相似检测中，出现将背景误识别为果串的情况，在果梗部分遮挡场景下也出现了错误定位采摘点的问题。YOLO12n-pose 在远景密集未成熟果串场景中，也存在将背景错检为果串或果梗的情况，而这会导致模型部署到自动化采摘设备时会出现较高的错误抓取或抓空问题。相较于对比模型，本文模型在上述场景中生成的检测框更紧凑且定位准确，降低了远景密集场景下的小尺度果梗的漏检率。因此，本文模型在温室复杂光照条件、重叠、遮挡及背景干扰等场景时都具有良好的鲁棒性与泛化能力。这为模型在边缘计算设备上实现高效、稳定的葡萄成熟度与果梗同步检测提供了可行的技术方案。

2.3　消融试验结果

本研究在 YOLO12n-pose 基准模型上逐步引入改进模块开展消融试验。在消融试验中，所有模型均使用相同的数据集，并在相同的参数条件下进行训练，结果见表 4。

分析表 4 可知，在 YOLO12n-pose 骨干网络中加入 RFAConv 模块后，模型对果串成熟度与果梗检测的召回率和 mAP 系列指标获得显著提升，但精确率分别下降至 84.3% 和 89.2%，这表明 RFAConv 模块降低了多尺度目标的漏检率。单独引入 EIFT 模块后，模型在成熟度检测中召回率、mAP@0.5 和 mAP@0.5-0.95 分别提升至 82.8%、88.0% 和 64.5%，验证其在遮挡、重叠和小尺度目标边缘特征的聚焦能力更强，但由于部分置信度背景特征的放大，也导致精确率下降至 84.2%。

当 RFAConv 和 EIFT 模块被同时嵌入至 YOLO12n-pose 时，模型对果串成熟度和果梗检测的各项指标上均

中国知网　https://www.cnki.net

有较好的提升，精确率分别提升了 0.7 和 0.4 个百分点，召回率分别提升了 2.0 和 3.2 个百分点。这表明改进模型的综合识别性能显著增加。深入分析发现：一方面，EIFT 模块侧重于多目标遮挡区域和模糊边缘细节的感知能力与建模能力，增强了模型的细粒度检测精度及其在复杂场景下的鲁棒性；另一方面，RFAConv 模块利用双通道并行机制，侧重于多尺度目标的全局上下文信息与局部感受野的动态优化，缓解了复杂背景中密集分布的多尺度目标检测中存在的特征混淆与信息丢失问题。两个模块在多尺度特征提取和感受野方面的协同增强效应，能够有效提升模型对多目标遮挡和边缘区域的特征聚集能力，降低了因部分重叠、遮挡或背景干扰导致的漏检现象。因此，消融试验验证了 RFAConv 和 EIFT 的联合使用在提升模型鲁棒性方面的有效性，使其能够更好地适应温室复杂光照条件与多尺度目标遮挡等挑战。



图 6 不同遮挡条件下不同模型识别结果对比

Fig.6 Comparison results of different models under different occlusion conditions

表 4 消融试验结果分析

Table 4 Results analysis of ablation experiments

检测目标 Detection target	模型 Model	*P*/%	*R*/%	mAP@0.5/%	mAP@0.5-0.95/%	计算量 FLOPs/G	参数量 Parameters/M
果串成熟度 Bunch ripeness	YOLO12n-pose	84.6	80.9	87.0	62.8	6.5	2.57
	YOLO12n-pose+RFAConv	84.3	83.8	88.2	64.2	7.1	2.69
	YOLO12n-pose+EIFT	84.2	82.8	88.0	64.5	7.8	3.22
	YOLO12n-pose+RFAConv+EIFT	85.3	82.9	88.9	65.4	8.4	3.33
果梗 Stem	YOLO12n-pose	89.4	73.3	81.8	36.8	6.5	2.57
	YOLO12n-pose+RFAConv	89.2	75.9	84.6	39.0	7.1	2.69
	YOLO12n-pose+EIFT	88.8	74.4	84.9	39.3	7.8	3.22
	YOLO12n-pose+RFAConv+EIFT	89.8	76.5	84.4	39.6	8.4	3.33

2.4 RBPM 算法匹配精度与采摘点定位对比试验分析

为评估 RBPM 算法匹配精度，在测试集中选取 10 张图像进行匹配，涵盖近景、远景、堆叠和遮挡场景下 26 个具备采摘条件的果串与采摘点。采用采摘点与果梗上边框中心点距离最近匹配方法与本文 RBPM 方法进行对比。结果表明，RBPM 成功匹配 25 个，而对比方法仅

中国知网 https://www.cnki.net

匹配成功 20 个，RBPM 能有效提升采摘的准确性。未成功匹配的原因主要是近距离匹配中果梗横向堆叠导致的采摘点遮挡。

为验证本文所提方法 GrapickNet 的采摘点定位精度，将模型预测的关键点坐标与人工标注坐标进行对比。在测试集中选取 1 820 个真实采摘点作为评价对象。首先采用基于 IoU 的最大匹配策略将预测果梗框与人工标注果梗框一一匹配；随后，在匹配成功的检测框对中，计算真实采摘点与预测采摘点之间的欧氏距离误差。表 5 是不同模型采摘点正确率和定位误差结果。

表 5　不同模型采摘点正确率和距离误差

Table 5　Accuracy and distance error of picking points for different models

模型 Model	采摘点检测精度 Picking point detection precision			距离误差 Location error		
	真实点数量 Number of observed points	识别点数量 Number of detected points	*P*/%	*X* 方向 *X*-direction	*Y* 方向 *Y*-direction	欧式距离 Euclidean distance
YOLOv5n-pose	1 820	1 219	66.9	2.65	6.28	7.34
YOLOv8n-pose	1 820	1 465	80.4	3.47	6.78	8.13
YOLOv10n-pose	1 820	1 455	79.9	3.41	5.73	7.55
YOLO11n-pose	1 820	1 446	79.4	2.49	5.54	6.51
YOLO12n-pose	1 820	1 417	77.8	2.62	5.81	6.81
GrapickNet	1 820	1 506	82.7	2.51	5.37	6.39

由表 5 可知，GrapickNet 模型共识别出 1 506 个真实采摘点，正确率达 82.7%。相较于 YOLO12n-pose 提升了 4.9%。在定位误差方面，本模型在 *X* 方向的平均误差为 2.51 像素，*Y* 方向平均误差为 5.37 像素，欧式距离平均误差为 6.39 像素。根据针孔相机投影模型，计算得实际物理定位误差范围为 8.25～13.20 mm。该视觉定位误差在采摘机器人机械容错半径（15 mm）之内，能确保采摘作业的成功执行[22]。除 *X* 方向误差略高于 YOLO11n-pose（相差 0.02 像素）外，其余各项误差指标均优于对比模型。因此，GrapickNet 在温室自然环境中采摘点识别及其定位精度方面均优于其他主流检测模型。此外，相较于先前小样本采摘点定位研究[25]，本文方法在 1 820 个大量采摘点定位验证中也达到了较好的精度。然而，当同一果串存在多个果梗时，模型可能出现采摘点重复识别的情况。

2.5　不同图像采集方式对比分析

为评估 GrapickNet 对不同采集方式的识别性能，从 3 类采集设备拍摄的图像中分别随机抽取 10 张进行对比测试。由表 6 可知，在不同采集方式下，GrapickNet 均能较好地同步识别果串成熟度和采摘点，成熟度和采摘点的平均检测精度分别为 89.2% 和 94.9%，具有良好的适应性。其中，成像质量最佳的索尼 ZV-E10 相机整体识别性能最优，一加 Ace3 手机次之，深度相机相对最低，三者性能差异与设备成像质量呈正相关。上述结果表明，本文模型对不同采集方式具有较好的鲁棒性。

2.6　果串成熟度和采摘点同步检测可视化结果

为评估本文方法在不同葡萄品种上的泛化能力，从 5 个品种中随机各抽取 15 张图像进行测试。由表 7 可知，GrapickNet 表现出良好的适应性和稳定性，对各品种葡萄成熟度和采摘点的平均检测精度分别达 94.9% 和 92.1%，显示出较强的跨品种识别能力。图 7 为 GrapickNet 不同品种葡萄的可视化检测结果，图 8 和图 9 分别为 Grapick-YOLO12n 和基准模型的热力图响应和感受野对比。

表 6　不同图像采集方式检测结果

Table 6　Detection results of different collection devices

采集设备 Variety	葡萄果串数量 Number of bunches	正确识别数量 Number of correctly identify	误检/错检数量 Number of false positive/ negative	可见采摘点数量 Number of visible picking points	识别采摘点数量 Number of picking points true detection
索尼 ZV-E10 相机 Sony ZV-E10 Camera	25	23	2	23	22
一加 Ace3 手机 OnePlus Ace3 smartphone	21	19	2	19	19
深度相机 Depth camera	20	17	3	18	16

表 7　不同品种葡萄果串成熟度和果梗采摘点检测结果

Table 7　Detection results of grape bunches ripeness and picking points across different varieties

品种 Variety	果串数量 Number of bunches	正确识别数量 Number of correctlyidentify	错误识别果串数量 Number of ripeness false detection	可见采摘点数量 Number of picking points	识别采摘点数量 Number of picking points true detection
玫瑰香 Muscat Hamburg	65	63	0	50	49
红提 Red Globe	44	43	1	38	35
蜜光 Miguang	44	41	2	35	32
查娜 Trepat	40	38	3	33	30
蓝宝石 Sweet Sapphire	36	35	4	33	29

由图 7 可以看出，GrapickNet 在温室不同光照条件下均表现出较高的识别性能，尤其在多目标密集、果实颜色失真、严重遮挡、远景与雨天低光照等多重挑战下，模型仍能实现较好的检测效果。果串和采摘点漏检或重复检测主要发生在检测目标和背景结构及颜色高度相似、果实颜色失真、阴影区域或叶片完全遮挡场景，占漏检总量的 90% 以上。分析原因发现，成熟度漏检主要源于目标局部特征发生混淆或强度衰减，这也与前人在葡萄果串和果梗识别上的研究结果一致[26-27]。果梗采摘点漏检则是由于在密集场景中果梗极易被叶片或相邻果串遮蔽，增加了识别难度。

图 8 结果显示，本文方法能更集中地响应果串、果梗及其采摘点区域分布，尤其在部分遮挡、重叠和远景场景下的特征激活更为鲜明，能有效规避基准模型在果串重叠、背景干扰和远景中存在的误检与漏检现象（如红色圆圈所示）。图 9 结果表明，本文方法在高阈值条件（0.99）下的高亮区域比例达到 0.959 8，优于对比模型。这表明本文方法能够更准确地捕获果串与果梗的显

中国知网　https://www.cnki.net

著区域，具备更均衡和广阔的感受野分布。也进一步验证了 EIFT 和 RFAConv 对多目标交织场景下特征感知和区分能力的提升，这也与 Yang 等[28] 对芽茶检测的研究结果一致。

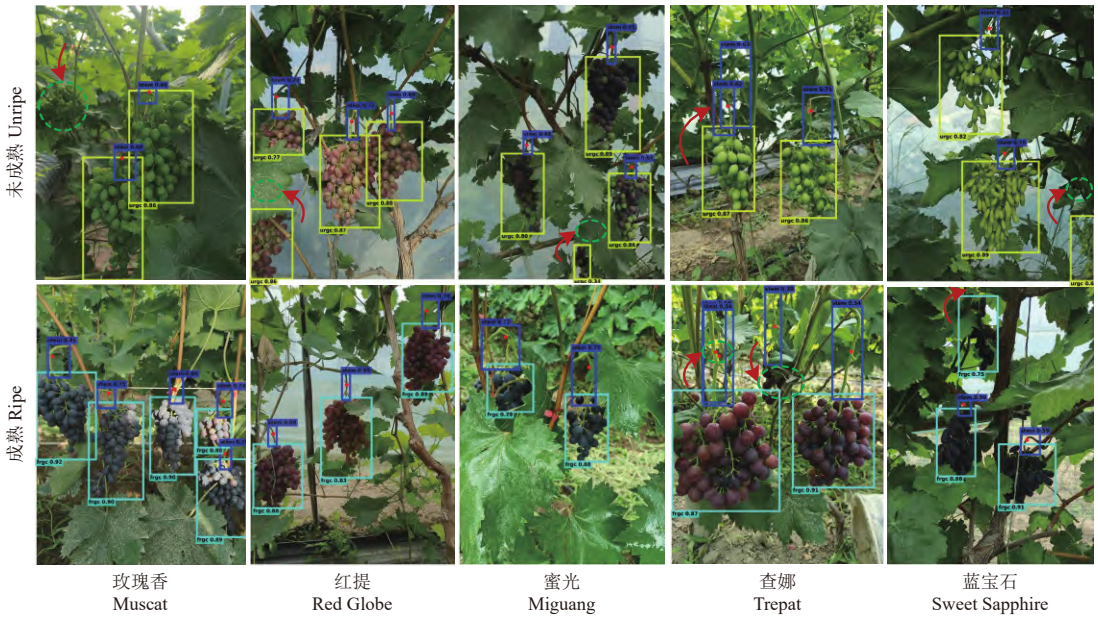


图 7 不同品种葡萄识别可视化结果

Fig.7 Visualiztion results of recognition different grape varieties

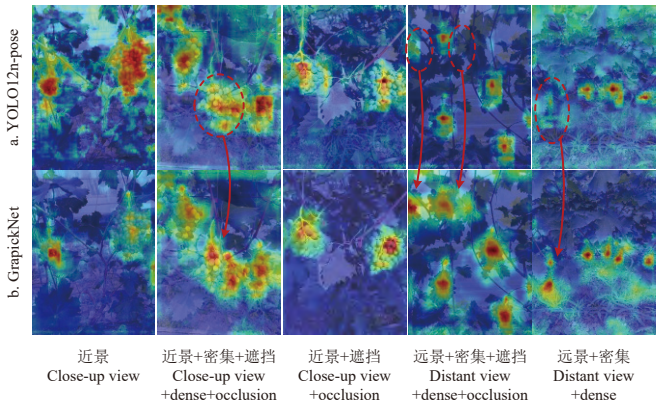


图 8 YOLO12n-pose 和 GrapickNet 热力图对比

Fig.8 Comparison of YOLO12n-pose and GrapickNet heatmaps

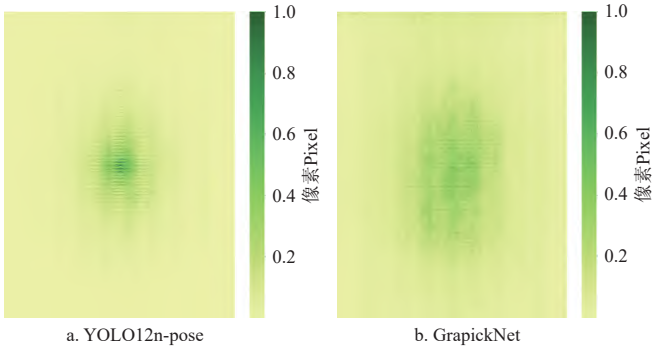


图 9 YOLO12n-pose 和 GrapickNet 感受野对比

Fig.9 Comparison of the receptive fields in YOLO12n-pose and GrapickNet

综上所述，本文方法增强了模型对关键特征的提取能力和定位能力，也克服了传统单一、分离检测任务的局限性。然而，本文方法在阴天条件下对不同尺度目标的识别精度出现分化。这一现象源于不同识别任务对光照条件的敏感性差异。阴天均匀的漫射光有效消除了极端光影干扰，有利于果梗轮廓特征的提取。而阴天环境下图像饱和度与对比度的降低削弱了色彩区分度，在一定程度上影响了果串成熟度的分类性能。因此，尽管模型整体鲁棒性良好，但其不同子任务对特定光照仍存在敏感性、且在目标与背景高度相似、完全遮挡等复杂场景下的精度仍有提升空间。此外，当前未成熟雨天样本数据规模相对有限，算法欧式距离阈值设置在近距离（0.3～0.5 m）和远距离（0.8～1.5 m）拍摄时存在一定局限性。未来工作将进一步扩展不同天气条件下样本数量并探索半监督学习、多光谱数据与时序信息融合及自适应距离约束，以提升模型在复杂环境下的多任务检测性能和泛化能力。

3 结 论

本文提出一种用于葡萄成熟度和采摘点同步检测的深度学习方法。构建了 5 个品种的专用葡萄 RGB 图像数据集，设计 Grapick-YOLO12n 改进模型和 RBPM 算法，实现了复杂温室场景中不同品种葡萄成熟度与采摘点的同步、准确和高效检测。

1）Grapick-YOLO12n 模型对果串成熟度检测的精确率、召回率、mAP@0.5 和 FLOPs 分别为 85.3%、82.9%、88.9% 和 8.4 G。对果梗检测的精确率、召回率、mAP@0.5 分别为 89.8%、76.5% 和 84.4%。在多目标、不同光照条件、有无遮挡、远景、近景及不同天气下都表现出较好的检测效果，能够满足温室复杂环境下的葡萄成熟度与果梗检测。

中国知网 https://www.cnki.net

2）在 1 820 个真实采摘点中，本文方法识别正确率为 82.7%。在定位误差方面，本文方法在 X 方向的平均误差为 2.51 像素，Y 方向平均误差为 5.37 像素，欧式距离平均误差为 6.39 像素。本文研究结果具有良好的实用性，参数量为 3.33 M，在计算效率与移动设备部署方面更具优势。可为复杂温室场景下的不同品种葡萄成熟度和采摘点同步检测提供高效的技术支撑，进一步推动葡萄采摘机器人智能化作业的发展。

[参 考 文 献]

[1] 周馨曌，吴烽云，邹湘军，等. 基于多目标识别的葡萄果串采摘点定位方法[J]. 农业工程学报，2023，39(22)：166-177.
Zhou Xinzhao, Wu Fengyun, Zou Xiangjun, et al. Method for locating picking points of grape clusters using multi-object recognition[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2023, 39(22): 166-177. (in Chinese with English abstract)

[2] Zhao R, Zhu Y, Li Y. An end-to-end lightweight model for grape and picking point simultaneous detection[J]. Biosystems Engineering, 2022, 223: 174-188.

[3] 杨艳芬，王全九，白云岗，等. 极端干旱地区滴灌条件下葡萄生长发育特征[J]. 农业工程学报，2009，25(12)：45-50.
Yang Yanfen, Wang Quanjiu, Bai Yungang, et al. Characteristics of grape growth and development under drip Irrigation conditions in extreme drought areas[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2009, 25(12): 45-50. (in Chinese with English abstract)

[4] Yin M, Huo L, Li N, et al. Packaging performance evaluation and freshness intelligent prediction modeling in grape transportation[J]. Food Control, 2024, 165: 110684.

[5] Tsakiridis N, Samarinas N, Kokkas S, et al. In situ grape ripeness estimation via hyperspectral imaging and deep autoencoders[J]. Computers and Electronics in Agriculture, 2023, 212: 108098.

[6] 蒋雪松，计恺豪，姜洪喆，等. 深度学习在林果品质无损检测中的研究进展[J]. 农业工程学报，2024，40(17)：1-16.
Jiang Xuesong, Ji Kaihao, Jiang Hongzhe, et al. Research progress of non-destructive detection of forest fruit quality using deep learning[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(17): 1-16. (in Chinese with English abstract)

[7] Lyu H, Grafton M, Ramilan T, et al. Synthetic hyperspectral reflectance data augmentation by generative adversarial network to enhance grape maturity determination[J]. Computers and Electronics in Agriculture, 2025, 235: 110341.

[8] Gutiérrez S, Tardaguila J, Fernández-novales J, et al. On-the-go hyperspectral imaging for the in-field estimation of grape berry soluble solids and anthocyanin concentration[J]. Australian Journal of Grape and Wine Research, 2019, 25(1): 127-133.

[9] 马鹏伟，周杰. 基于改进 YOLOv7 的复杂环境下的葡萄成熟度检测[J]. 农业工程学报，2025，41(3)：171-178.
Ma Pengwei, Zhou Jie. Detecting grape ripeness in complex environments using improved YOLOv7[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(3): 171-178. (in Chinese with English abstract)

[10] Xiong J, Lin R, Liu Z, et al. The recognition of litchi clusters and the calculation of picking point in a nocturnal natural environment[J]. Biosystems Engineering, 2018, 166: 44-57.

[11] Bai Y, Mao S, Zhou J, et al. Clustered tomato detection and picking point location using machine learning-aided image analysis for automatic robotic harvesting[J]. Precision Agriculture, 2022, 24: 727-743.

[12] 杜文圣，王春颖，朱衍俊，等. 采用改进 Mask R-CNN 算法定位鲜食葡萄疏花夹持点[J]. 农业工程学报，2022，38(1)：169-177.
Du Wensheng, Wang Chunying, Zhu Yanjun, et al. Fruit stem clamping points location for table grape thinning using improved mask R-CNN[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2022, 38(1): 169-177. (in Chinese with English abstract)

[13] 杨震宇，汪小昆，祁子涵，等. 基于改进 YOLOv8 的草莓识别与果梗采摘关键点检测[J]. 农业工程学报，2024，40(18)：167-175.
Yang Zhenyu, Wang Xiaochan, Qi Zihan, et al. Recognizing strawberry to detect the key points for peduncle picking using improved YOLOv8 model[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2024, 40(18): 167-175. (in Chinese with English abstract)

[14] Yan J, Liu Y, Zheng D, et al. Grasping and cutting points detection method for the harvesting of dome-type planted pumpkin using transformer network-based instance segmentation architecture[J]. Frontiers in Plant Science, 2023, 14: 1063996.

[15] Wu Z, Xia F, Zhou S, et al. A method for identifying grape stems using keypoints[J]. Computers and Electronics in Agriculture, 2023, 209: 107825.

[16] Chen J, Ma A, Huang L, et al. Efficient and lightweight grape and picking point synchronous detection model based on key point detection[J]. Computers and Electronics in Agriculture, 2024, 217: 108612.

[17] 宁政通，罗陆锋，廖嘉欣，等. 基于深度学习的葡萄果梗识别与最优采摘定位[J]. 农业工程学报，2021，37(9)：222-229.
Ning Zhengtong, Luo Lufeng, Liao Jiaxin, et al. Recognition and the optimal picking point location of grape stems based on deep learning[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2021, 37(9): 222-229. (in Chinese with English abstract)

[18] Luo L, Liu B, Chen M, et al. DRL-enhanced 3D detection of occluded stems for robotic grape harvesting[J]. Computers and Electronics in Agriculture, 2025, 229: 109736.

[19] Jin Y, Yu C, Yin J, et al. Detection method for table grape ears and stems based on a far-close-range combined vision system and hand-eye-coordinated picking test[J]. Computers and

中国知网　https://www.cnki.net

Electronics in Agriculture, 2022, 202: 107364.
[20] Wang Q, Xu F, Chen Q, et al. Detection and location of wine grape (Cabernet Sauvignon) picking points by using a dual-stage deep learning method[J]. Computers and Electronics in Agriculture, 2025, 237(Part B): 110637.
[21] Tian Y, Ye Q, Doermann D. YOLOv12: Attention-centric real-time object detectors[C]. //Computer Vision and Pattern Recognition, 2025, arXiv: 2502.12524. Available: https://doi.org /10.48550/arXiv.2502.12524.
[22] Li P, Chen J, Chen Q, et al. Detection and picking point localization of grape bunches and stems based on oriented bounding box[J]. Computers and Electronics in Agriculture, 2025, 233: 110168.
[23] Zhang S, Hu K, Sha W, et al. Efficient one-stage location method for grape picking points in natural scene by combining detection network and point regression[J]. Computers and Electronics in Agriculture, 2025, 230: 109725.
[24] Zhang J, Hu T, He H, et al. EMOv2: Pushing 5M vision model frontier[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025, 47(11): 10560-10576.
[25] Zhang T, Wu F, Wang M, et al. Grape-bunch identification and location of picking points on occluded fruit axis based on YOLOv5-GAP[J]. Horticulturae, 2023, 9(4): 498.
[26] Li H, Li C, Li G, et al. A real-time table grape detection method based on improved YOLOv4-tiny network in complex background[J]. Biosystems Engineering, 2021, 212: 347-359.
[27] Liu B, Zhang Y, Wang J, et al. An improved lightweight network based on deep learning for grape recognition in unstructured environments[J]. Information Processing in Agriculture, 2024, 11(2): 202-216.
[28] Yang Q, Gu J, Xiong T, et al. RFA-YOLOv8: A Robust Tea Bud Detection Model with Adaptive Illumination Enhancement for Complex Orchard Environments[J]. Agriculture, 2025, 15(18): 1982.

Detecting grape ripeness to synchronously locate picking point during harvesting

Liu Rui[1] , Chang Shuaibing[1] , Jin Zhugui[1] , Ge Yongqi[1,2] , Sun Zhifeng[3]

(1. *School of Information Engineering*, *Ningxia University*, *Yinchuan* 750021, *China*; 2. *Ningxia Key Laboratory of Artificial Intelligence and Information Security for Channeling Computing Resources from the East to the West*, *Yinchuan* 750021, *China*; 3. *Yinchuan Fangda Electronic System Engineering Co.*, *Ltd*, Yinchuan 750021, *China*)

Abstract: Fruit harvesting is often required to synchronously detect ripe grapes and their picking points in robotics. However, conventional asynchronous grape detection cannot fully meet the large-scale production in recent years, such as complex operation, low efficiency, high model redundancy, and high computational cost. In this study, a synchronous model, GrapickNet, was proposed to detect grape ripeness and picking points. An improved Grapick-YOLO12n model was also employed to simultaneously detect grape ripeness and stem points. A bunch-pick point matching algorithm was then utilized to effectively match ripe bunches with their pick points, according to multiple constraint rules (RBPM). 1) Taking YOLO12n-pose as the baseline model, Grapick-YOLO12n framework was integrated the Edge Information Transfer (EIFT) and the C3K2_RFAConv module. Among them, the EIFT module was used to enhance the perception of object boundaries and local elongated small targets using shallow multi-scale edge feature extraction and cross-channel fusion mechanisms. The C3K2_RFAConv module was used to expand the receptive field and strengthen global context modeling for the feature discrimination under complex scenes and multiple targets. 2) Multiple constraints were constructed to improve the successful matching rate between ripe bunches and its picking point using RBPM algorithm. A dataset was constructed as model training data. 4 383 RGB images of greenhouse grapes were captured under two environments, four lighting conditions, and five varieties. Experimental results showed that GrapickNet achieved 88.9% mAP@0.5 for ripeness detection and 82.7% precision for picking point detection. Compared with the baseline model (87.0% mAP@0.5 for ripeness and 77.8% precision for picking points), the performance improved by 1.9% and 4.9%, respectively. Furthermore, the computational complexity of 8.4 GFLOPs and a parameter size of only 3.33 M were obtained with an inference speed of 94.6 FPS. In terms of positioning accuracy, the average errors in the *X* and *Y* directions were 2.51 and 5.37 pixels, respectively. The average error was 6.39 pixels in Euclidean distance. The performance of object detection outperformed the existing models, including YOLOv5n-pose, YOLOv8n-pose, YOLOv10n-pose, YOLO11n-pose, YOLO12n-pose, Faster R-CNN, SSD, and RT-DETR. Compared with asynchronous separate detection tasks, GrapickNet shared multi-task synchronous detection for the synchronous, accurate, and efficient detection of fruit ripeness and picking points for different grape varieties in complex greenhouse scenarios. The high accuracy and short detection time were reduced parameter usage for the computational efficiency and deployment on mobile devices. This finding can also provide an efficient and accurate technical solution for grape harvesting robots in semi-structured greenhouses.

Keywords: grape; ripeness; YOLO12n-pose; synchronous detection; picking point

中国知网 https://www.cnki.net